Predicción de la deforestación en la Amazonía peruana mediante redes neuronales: un enfoque espacio-temporal con redes convolucionales y mecanismos de atención sobre series históricas satelitales

Gerardo Manuel Barzola Salvador
Maestría en Ingeniería de Inteligencia Artificial
FIIS – UNI
Lima, Perú
gerardo.barzola.s@uni.pe

Rocío Ivett Castromonte Quiroz
Maestría en Ingeniería de Inteligencia Artificial
FIIS – UNI
Lima, Perú
rocio.castromonte.q@uni.pe

José Luis Núñez Veintimilla
Maestría en Ingeniería de Inteligencia Artificial
FIIS – UNI
Lima, Perú
j.nunez.v@uni.pe

Ubil Rodríguez Arrascue
Maestría en Ingeniería de Inteligencia Artificial
FIIS – UNI
Lima, Perú
ubil.rodriguez.a@uni.pe

Miguel Ángel Salinas Marcos
Maestría en Ingeniería de Inteligencia Artificial
FIIS – UNI
Lima, Perú
miguel.salinas.m@uni.pe

***Resumen*—Según los datos oficiales de Geobosques, la Amazonía peruana perdió cerca de tres millones de hectáreas de bosque entre 2001 y 2022, y anticipar dónde ocurrirá la próxima pérdida permitiría priorizar la fiscalización y la conservación con recursos limitados. Planteamos la predicción, con un año de anticipación, de la pérdida de bosque en celdas de unos 278 m en toda la Amazonía peruana. Construimos un conjunto de datos que armoniza ocho fuentes públicas en 37 canales: la pérdida anual oficial de Geobosques, la cobertura de bosque, el relieve, la lluvia, las áreas naturales protegidas, las vías y ríos, y el uso del suelo, con una partición temporal sin fuga (años objetivo: entrenamiento 2016–2021, validación 2022–2023, prueba 2024–2025). Sobre este conjunto comparamos cinco redes de segmentación de tres familias: una U-Net como línea base, TransUNet++ y Swin UNETR, que incorporan atención, y dos redes siamesas, entre ellas nuestro modelo propuesto, la Siamese Forest U-Net, que contrasta el bosque de 2000 con el remanente y es la única que usa la historia de pérdida (37 canales); además, un clasificador ResNet50 y líneas base clásicas por parche. Evaluado por celda y con la proporción real de pérdida, el modelo propuesto alcanza en validación un F1 de 0.362: de cada 100 celdas que señala como de riesgo, 28 pierden bosque, unas 10 veces más que una selección al azar; aún no se ha evaluado en prueba. Entre los modelos evaluados en prueba, todos de 31 canales, el mejor es Swin UNETR, con un F1 de 0.237 frente a 0.207 de la U-Net: unas 20 de cada 100 celdas señaladas pierden bosque, 8 veces más que al azar. Las ablaciones muestran que el término Dice y las conexiones de salto son indispensables, y que agregar un Transformer a la U-Net o una rama siamesa no la mejora. Los resultados sugieren que la historia de pérdida aporta más que la complejidad de la arquitectura, hipótesis que debe confirmarse con una evaluación en prueba y una ablación controlada.**

***Palabras clave*—aprendizaje profundo, deforestación, Amazonía peruana, U-Net, datos geoespaciales, pronóstico espacio-temporal**

I. Introducción

La Amazonía peruana concentra la mayor parte de los bosques del país y es una de las regiones más biodiversas del planeta. Su pérdida, impulsada por la expansión agropecuaria, la apertura de vías, la tala y la minería [1], libera carbono, fragmenta hábitats y afecta a comunidades que dependen del bosque. Según la plataforma oficial GEOBOSQUES [2], entre 2001 y 2022 se perdieron cerca de tres millones de hectáreas. Ese monitoreo informa *dónde ya se perdió* el bosque; para orientar patrullajes, planificar áreas de conservación o evaluar proyectos de carbono, se necesita estimar *dónde es probable que se pierda* en el futuro cercano.

Formulación del problema. Dividimos la Amazonía peruana en celdas de 0.0025° ($\approx$278 m, unas 7.6 ha). Dado

el estado de cada celda y de su entorno en el año t (historia de pérdida, bosque remanente, lluvia, relieve, protección legal, accesibilidad y uso del suelo), se busca estimar la probabilidad de que la celda registre pérdida de bosque en el año $t+1$. La entrada es un parche de $37 \times 128 \times 128$ (unos 36×36 km) y la salida, un mapa de probabilidad del mismo tamaño. Como solo entre 2 y 3.6 % de las celdas con bosque pierde cobertura cada año, el éxito se mide con métricas para clases desbalanceadas (precisión, *recall*, F1 e IoU de la clase pérdida) y sobre la proporción real de pérdida, sin balancear el conjunto de prueba.

¿Por qué aprendizaje profundo? La deforestación avanza como un *frente*: se propaga desde bordes, caminos, ríos y chacras existentes [3], [4], y depende de cómo se combinan en el espacio el acceso, el relieve, la protección legal y el uso previo del suelo. Las redes convolucionales de tipo U-Net [5] aprenden esos patrones a varias escalas directamente de los mapas y producen una predicción por celda; los mecanismos de atención [6] permiten además relacionar zonas lejanas del parche, como una vía a decenas de kilómetros; y las redes siamesas [7] comparan dos estados del bosque para resaltar dónde ya cambió. Por eso comparamos estas tres familias sobre los mismos datos.

Novedad respecto al curso. El proyecto no replica un laboratorio: construye un conjunto de datos propio para el Perú que integra ocho fuentes oficiales y abiertas, con aumento de datos diseñado para el error típico de cada fuente, y lo usa para pronosticar, no para segmentar una imagen. La partición es temporal, aunque algunas covariables no son estrictamente históricas, limitación que se analiza en la Sección V.

Las contribuciones de este trabajo son:

- Un conjunto de datos multifuente de 37 canales para toda la Amazonía peruana (2001–2025), con partición temporal sin fuga, normalización calculada solo con entrenamiento y aumento de datos específico por fuente, publicado con el código para regenerarlo.
- La comparación de cinco redes de segmentación de tres familias (CNN tipo U-Net, modelos con Transformer y redes siamesas) con la misma partición y el mismo protocolo, más una arquitectura propuesta, la Siamese Forest U-Net, que contrasta el bosque de 2000 con el remanente y se evaluó por ahora solo en validación.
- Una evaluación sobre la proporción real de pérdida, sin balancear la prueba, con ablaciones de los componentes, interpretabilidad con Grad-CAM, análisis de errores y costo computacional.

El resto del artículo se organiza así: la Sección II revisa trabajos relacionados; la Sección III describe la metodología; la Sección IV presenta los resultados, que se discuten en la Sección V; la Sección VI concluye.

II. Trabajos relacionados

Factores de la deforestación en la Amazonía peruana. Rojas *et al.* [3] modelaron con Maxent el riesgo en toda la Amazonía peruana a 100 m con los datos oficiales 2001–2019 (AUC de 0.749): la distancia a tierras agrícolas (59.7 % de contribución) y a caminos (17.9 %) fueron las variables más informativas, y aunque menos del 1 % del bosque de las áreas protegidas nacionales quedó en riesgo muy alto, en las zonas de amortiguamiento la cifra subió a 15 %. García Soto y Koelle [1], con los mapas de MapBiomas Perú, estimaron que cerca del 90 % de la pérdida de bosque del país desde 2000 ocurrió en la Amazonía y que la agricultura explica alrededor del 80 % de la pérdida neta de cobertura forestal, mientras que la minería, la tala ilegal y los cultivos ilícitos tienen una incidencia más local. Estos estudios justifican las fuentes que usamos (vías, ríos, lluvia, relieve, protección y uso del suelo), pero emplean modelos estadísticos que no aprenden patrones espaciales; nosotros las integramos como canales de redes profundas.

Pronóstico de la deforestación con aprendizaje profundo. Ball *et al.* [8] usaron por primera vez CNN 2D, CNN 3D y ConvLSTM para pronosticar, píxel a píxel a 30 m, la pérdida del año siguiente en Madre de Dios y Junín; la mejor, una CNN 3D, alcanzó un AUC de 0.84 a 0.89 y una sensibilidad de 0.58 a 0.72 en 2020. Sin embargo, su conjunto de prueba estaba balanceado 4:1 entre píxeles sin pérdida y con pérdida. Engelmann y Toetzke [9] reimplementaron ese modelo en la Amazonía brasileña: con la prueba submuestreada obtuvo un F1 de 0.725, pero con la proporción real bajó a 0.197; su U-Net llegó a 0.263 por píxel y a 0.608 al agregar en celdas de 1.5 km. Más recientemente, ForestCast [4] publicó el primer conjunto de datos abierto para pronosticar el riesgo de deforestación con aprendizaje profundo, en el sudeste asiático: comparó varios modelos profundos y un bosque aleatorio, y encontró que el historial de pérdida mejora el desempeño en la mayoría de los casos y por sí solo basta para obtener buenos resultados, mientras que capas auxiliares como la pendiente o la distancia a vías aportan poco a los mejores modelos. Elezi y Garza [10] replantearon el pronóstico en la Amazonía brasileña como un problema de *ranking* espacial (entrenamiento con 2018–2024 y prueba en 2025) y mejoraron la priorización de zonas frente a las pérdidas de regresión convencionales. Nuestro trabajo sigue el protocolo más exigente de [9] (prevalencia real y partición independiente) y se diferencia de estos trabajos en (i) cubrir toda la Amazonía peruana con los datos oficiales de Geobosques, (ii) combinar ocho fuentes, incluidas las áreas protegidas y el uso del suelo, y (iii) comparar cinco redes de segmentación de tres familias.

Arquitecturas base. La U-Net [5] combina un codificador y un decodificador simétricos con conexiones de salto, y ganó el desafío ISBI 2015 de seguimiento celular con un IoU de 0.920; sigue siendo una referencia en deforestación: en la detección de la pérdida en el sur de la Amazonía con radar Sentinel-1 fue el modelo con menor error [11]. Las redes residuales [12] permiten entrenar codificadores profundos mediante atajos de identidad y se usan como *backbone* de la U-Net. El Transformer [6] reemplaza la recurrencia por atención multi-cabeza; TransUNet [13] lo usa como codificador de una U-Net y mejoró el Dice en segmentación multiórgano de 74.68 % a 77.48 %, y Swin UNETR [14] usa un Swin Transformer jerárquico con ventanas desplazadas (Dice medio

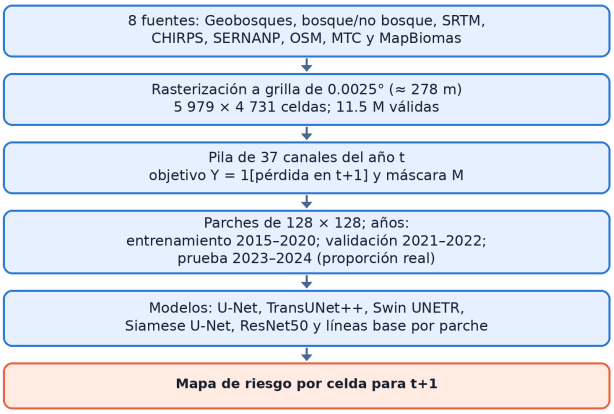


Figura 1. Flujo de trabajo: de las ocho fuentes públicas al mapa de riesgo de pérdida de bosque para el año $t+1$.

de 0.913 en BraTS 2021); en teledetección forestal, Swin-UNet superó de forma consistente a la U-Net en la clasificación de tipos de bosque [15]. UNet++ [16] reemplaza las conexiones de salto por rutas anidadas y densas, y SegFormer [17] combina un codificador Transformer jerárquico eficiente con un decodificador ligero de capas lineales. Finalmente, las redes siamesas totalmente convolucionales de Daudt *et al.* [7] detectan cambios entre dos imágenes satelitales con un codificador de pesos compartidos; la variante que usa la diferencia absoluta entre ramas (FC-Siam-diff) fue la mejor con imágenes de 13 bandas (F1 de 57.92). Todas estas arquitecturas se diseñaron para imágenes del presente; nosotros las adaptamos para pronosticar el año siguiente a partir de 37 canales geoespaciales.

III. Metodología

III-A. Datos

Área y grilla común. El área de estudio es la Amazonía peruana (lon. $-80.5°$ a $-68.7°$, lat. $-15.0°$ a $0.0°$). Todas las fuentes se llevan a una grilla común de $0.0025°$ ($\approx$278 m) en EPSG:4326, de $5\,979 \times 4\,731$ celdas, de las cuales 11.5 M quedan dentro del límite y con datos válidos de relieve y lluvia. La Tabla I resume las ocho fuentes y cómo se transforma cada una. La Fig. 1 resume el flujo completo, desde las fuentes hasta el mapa de riesgo.

Pérdida de bosque. La fuente principal es la pérdida anual oficial de Geobosques [2], distribuida como 7.57 millones de polígonos de 30 m con el año de pérdida. Los polígonos se pintan primero en un raster fino de $\approx$28 m ($10\times$ la grilla) y luego cada bloque de 10×10 se resume como la fracción perdida en cada año, $P_y \in [0, 1]$. Para el año 2025, Geobosques separa la pérdida antrópica de la natural (derrumbes, cambios de cauce), que representa 9.8 % de ese año; se usa solo la antrópica.

Variables dinámicas. A partir de P_y se calculan, para cada año t, seis canales: la pérdida del año P_t; la pérdida reciente $R_t = \sum_{y=t-2}^{t} P_y$; la pérdida acumulada $A_t = \min\left(1, \sum_{y\le t} P_y\right)$; el logaritmo de la distancia a la pérdida reciente y a cualquier pérdida previa, $\log(1+d)$; y la densidad de pérdida reciente en una ventana de 21×21 celdas ($\approx$6 km).

Bosque, objetivo y máscara. El bosque en 2000 se reconstruye como la fracción de bosque en 2025 más la pérdida posterior, B_{2000}; el bosque remanente es $B_{2000} - A_t$. El objetivo es binario por celda,

$$Y_t(i) = \mathbf{1}\big[P_{t+1}(i) > 0\big], \tag{1}$$

es decir, si la celda registra alguna pérdida en el año siguiente. La máscara $M_t(i) = \mathbf{1}\big[i \in \text{área válida} \wedge B_{2000}(i) - A_t(i) > 0.02\big]$ conserva solo las celdas que todavía tienen bosque; restringirla así reduce las celdas candidatas en 15 % y sube la prevalencia de 2.39 a 2.80 % (año $t = 2021$). La máscara se usa en la función de pérdida y en las métricas, no como entrada.

Variables de contexto. La lluvia de CHIRPS v3 [19] se representa como la climatología trimestral y anual 2015–2025 y como la anomalía del año t. El relieve (elevación y pendiente) proviene de SRTM [18]. Para las áreas protegidas [20], el nivel de protección (3 = ANP nacional, 2 = zona reservada o área regional, 1 = área privada, 0 = ninguna) y la distancia firmada al borde se calculan con las áreas *que ya existían en el año* t, según su fecha de creación. En el año 2022, la proporción de celdas con pérdida fue de 3.63 % sin protección, 0.55 % en zonas reservadas o áreas regionales y 0.40 % en ANP nacionales, lo que confirma que la protección es informativa. La accesibilidad se describe con la distancia a vías, trochas, ríos y centros poblados de OpenStreetMap [21] y a la red vial oficial del MTC [22]. Finalmente, MapBiomas Perú [23] aporta la fracción de uso agropecuario, minero, urbano, de formaciones naturales no boscosas y de agua, y la distancia a lo agropecuario y a la minería. Como MapBiomas usa los años vecinos para limpiar cada mapa, para el año t se usa el mapa de $t-1$.

Normalización. Cada canal se estandariza, $\tilde{x} = (x - \mu)/\sigma$, con la media y la desviación estándar de 100 000 celdas muestreadas *solo* de los años de entrenamiento.

Partición sin fuga. Como el objetivo de un año es la entrada de pérdida del año siguiente, los conjuntos se separan por año y nunca al azar (Tabla II). En entrenamiento se eligen 800 centros de parche por año, la mitad donde hay pérdida reciente (densidad > 0.02) porque la clase positiva es rara, y se guardan dos versiones de cada uno (original y aumentada). Validación y prueba recorren toda el área con el mismo mosaico de 701 parches de 128×128 sin solapamiento, uno por cada año, de modo que sus métricas reflejan la frecuencia real de la deforestación; ambos conjuntos comparten las posiciones pero no los años. Todos los modelos, incluida E1, usan exactamente estos mismos arreglos; sus metadatos listan los años de entrada t (2015–2020, 2021–2022 y 2023–2024), que corresponden a los años objetivo $t+1$ citados en el texto (2016–2021, 2022–2023 y 2024–2025).

Distribución de clases. La Tabla II resume las celdas válidas (dentro de la máscara) y las positivas de cada conjunto. Por el muestreo dirigido, la proporción de positivos en los

Tabla I
FUENTES DE DATOS, TRANSFORMACIÓN A LA GRILLA COMÚN (≈278 M) Y CANALES RESULTANTES

Fuente	Original	Transformación	Canales
Pérdida de bosque 2001–2025, Geobosques [2]	7.57 M polígonos de 30 m (UTM 18S); año en `gridcode`	Raster fino de ≈28 m y fracción perdida por año en cada celda; se excluye la pérdida natural de 2025	6 dinámicos + objetivo
Bosque y no bosque, Geobosques [2]	Raster de clases de 30 m	Fracción por clase; bosque 2000 = bosque 2025 + pérdida	2 + máscara
SRTM [18]	Elevación y pendiente de ≈93 m	Promedio por celda	2 fijos
CHIRPS v3 [19]	Lluvia trimestral y anual de ≈5.5 km (2015–2025)	Interpolación bilineal; climatología y anomalía del año t	5 fijos + 5 dinámicos
Áreas naturales protegidas, SERNANP [20]	5 capas de polígonos con fecha de creación	Rasterización solo de las áreas existentes en t; nivel de protección y distancia firmada al borde	3
OpenStreetMap [21]	Líneas y puntos (foto de 2026)	Rasterización y log de la distancia a vías principales, trochas, ríos y poblados	4 fijos
Red vial MTC [22]	Red nacional, departamental y vecinal (2018)	Rasterización y log de la distancia	3 fijos
MapBiomas Perú [23]	Clases anuales de 30 m (2013–2025)	Fracción por grupo (agropecuario, minería, urbano, no boscosa, agua) y distancias; se usa el mapa de $t-1$	7 dinámicos
Total			**37 canales**

Tabla II
PARTICIÓN TEMPORAL Y DISTRIBUCIÓN DE CLASES (CELDAS DENTRO DE LA MÁSCARA)

Conjunto	Años t	Obj. $t{+}1$	Parches	Celdas	Pos. (%)
Entrenamiento	2015–2020	2016–2021	9 600[a]	145.7 M	6.89
Validación	2021–2022	2022–2023	1 402	19.5 M	2.82
Prueba	2023–2024	2024–2025	1 402	19.5 M	2.52

[a] 4 800 centros × 2 copias (original y aumentada). Pos.: % de celdas con bosque que pierden bosque en $t+1$.

parches de entrenamiento es de 6.89 % (11.2 % en los parches elegidos cerca de pérdida reciente y 2.7 % en los elegidos al azar), mientras que en validación y prueba es de 2.82 % y 2.52 %, igual a la del área completa. En entrenamiento, 1.5 % de los parches no tiene ningún positivo; en validación y prueba, 7.2 % y 6.6 %. Esta diferencia de prevalencia obliga a elegir el umbral de decisión en validación y no en entrenamiento.

Protocolo de uso. Todos los modelos se entrenan solo con el conjunto de entrenamiento. El conjunto de validación se usa para comparar modelos, elegir la época del mejor modelo, ajustar hiperparámetros con Optuna y fijar el umbral de decisión. El conjunto de prueba se evalúa una sola vez, al final, con el umbral de validación, y sus predicciones alimentan el prototipo de visualización; nunca se usa para tomar decisiones de modelado.

Aumento de datos. Como el modelo ve pocos años distintos, durante el entrenamiento se generan variaciones realistas de cada parche. Las *geométricas* se aplican igual a todos los canales, al objetivo y a la máscara: rotaciones de 90° y espejo, rotación libre, escala de 0.85 a 1.15× (corrigiendo las distancias) y deformación elástica; los canales categóricos, el objetivo y la máscara se interpolan por vecino más cercano. Las *específicas por fuente* simulan el error típico de cada una: omisión del 10 % de las detecciones de pérdida, ruido en la fracción de bosque, error multiplicativo de ±10 % en la lluvia, error vertical de ±8 m en la elevación, límites de áreas protegidas desplazados una celda, borrado de tramos de vías y poblados de OpenStreetMap y del MTC (con recálculo de distancias), y ruido y omisión de manchas en MapBiomas. Al final se aplica *cutout* y, con probabilidad 0.1, se apaga una fuente completa para que el modelo no dependa de una sola. El objetivo y la máscara solo cambian con las transformaciones geométricas, y no se aumenta en validación ni en prueba.

III-B. Arquitecturas comparadas

Todos los modelos reciben parches de 128×128 y se entrenan desde cero con el mismo conjunto de entrenamiento, pero no con los mismos canales: U-Net, Siamese U-Net, TransUNet++ y Swin UNETR usan 31 canales, porque su plantilla de código excluyó por defecto los seis canales de historia de pérdida, mientras que la Siamese Forest U-Net y ResNet50 usan los 37. Las redes de segmentación producen un logit por celda; ResNet50 da una sola salida por parche. La Tabla III resume las arquitecturas.

U-Net (línea base). U-Net [5] de cuatro reducciones, con bloques de dos convoluciones 3×3, BatchNorm y ReLU, de 32 a 512 canales, decodificador con interpolación bilineal y conexiones de salto, y la misma cabeza auxiliar por parche que los demás modelos (7.77 M parámetros). Es la línea base profunda exigida por el requisito R3.

TransUNet++. Combina dos ideas. De TransUNet [13] toma un codificador convolucional de cinco niveles ($32 \to 64 \to 128 \to 256 \to 512$ canales, bloques de dos convoluciones 3×3 con BatchNorm y ReLU) cuyo cuello de botella de 8×8 se aplana en 64 *tokens* y pasa por un Transformer de 4 capas

Tabla III
MODELOS COMPARADOS

Modelo	Familia
U-Net [5]	CNN (línea base)
TransUNet++ [13], [16]	CNN + Transformer
ResNet50 [12]	CNN (clasificador por parche)
Swin UNETR [14]	Transformer de visión
SegFormer [17] (ablación)	Transformer de visión
Siamese U-Net (conc.) [7]	Red siamesa
Siamese Forest U-Net [7] (propuesto)	Red siamesa

(dimensión 256, 8 cabezas, normalización previa) [6], de modo que cada posición atiende a todo el parche y relaciona, por ejemplo, una vía con el bosque remanente lejano. De UNet++ [16] toma el decodificador con conexiones de salto anidadas y densas,

$$X^{i,j} = \mathcal{H}\big([X^{i,0}, \ldots, X^{i,j-1}, \mathrm{Up}(X^{i+1,j-1})]\big), \qquad (2)$$

donde $\mathcal{H}$ es un bloque convolucional, y supervisión profunda: cada nodo $X^{0,j}$ tiene su propia cabeza de segmentación y la predicción final promedia las cuatro. El modelo tiene 12.61 M parámetros.

ResNet50. ResNet-50 [12], con bloques residuales *bottleneck*, se usa como clasificador por parche: decide si el parche tendrá deforestación (fracción de celdas con pérdida en $t{+}1$ de al menos 5 %) o no. Como no produce un mapa por celda, se compara con los demás modelos con las métricas por parche, y su interpretación se analiza con Grad-CAM. Su primera convolución recibe los 37 canales.

Swin UNETR y SegFormer. Se implementaron versiones 2D de dos Transformers jerárquicos, entrenados con el mismo protocolo. En *Swin UNETR* [14], un *patch embedding* de 2×2 proyecta los 31 canales de entrada a 24 dimensiones y cuatro etapas Swin (2 bloques cada una, 3, 6, 12 y 24 cabezas, ventanas de 8×8 alternando ventanas fijas y desplazadas) con *patch merging* producen características a 1/4, 1/8, 1/16 y 1/32 de la resolución; un decodificador convolucional con bloques residuales y convoluciones transpuestas las combina mediante conexiones de salto. La versión original es 3D y fue diseñada para resonancia magnética, por lo que aquí se adaptó a 2D. En *SegFormer* [17], un codificador Mix Transformer de tipo B0 (dimensiones 32, 64, 160 y 256) usa *patch embedding* solapado, atención eficiente que reduce la resolución de claves y valores (razones 8, 4, 2 y 1) y una red de alimentación con convolución en profundidad en lugar de codificación posicional; un decodificador ligero de capas lineales fusiona las cuatro escalas. Se eligió Swin UNETR como modelo principal (6.32 M parámetros); SegFormer (3.76 M) se evalúa como arquitectura alternativa en las ablaciones. Ninguno usa pesos preentrenados. Swin UNETR usa además *dropout* de 0.3 y *drop path* de 0.1 en los bloques Transformer.

Siamese U-Net (concatenación). Sigue la variante FC-Siam-conc de Daudt *et al.* [7]: un codificador U-Net con pesos compartidos procesa dos vistas del mismo parche, el bosque de 2000 y el bosque remanente en t, cada una acompañada de las mismas covariables, y el decodificador concatena las características de ambas ramas en cada conexión de salto (9.08 M parámetros).

Siamese Forest U-Net (modelo propuesto). Adapta la red FC-Siam-diff de Daudt *et al.* [7], diseñada para detectar cambios entre dos imágenes, a dos *estados del bosque*: el bosque de 2000, B_{2000} (canal 6), y el bosque remanente en t, B_t (canal 7). Un mismo codificador U-Net E, con pesos compartidos, procesa cada estado. Tiene cuatro niveles, cada uno con dos convoluciones 3×3, BatchNorm y ReLU, y *max-pooling* entre niveles, con 16, 32, 64 y 128 canales. En cada escala l se combinan ambas representaciones con su diferencia absoluta, que resalta dónde ya cambió el bosque:

$$\mathbf{F}^{(l)} = \phi_l\Big(\big[\,E^{(l)}(B_{2000})\,;\; E^{(l)}(B_t)\,;\; \big|E^{(l)}(B_{2000}) - E^{(l)}(B_t)\big|\,\big]\Big), \qquad (3)$$

donde $[\cdot\,;\cdot]$ es la concatenación por canales y ϕ_l un bloque de dos convoluciones. El decodificador sube la resolución con interpolación bilineal y concatena en cada nivel la fusión $\mathbf{F}^{(l)}$ correspondiente, hasta volver a $16 \times 128 \times 128$. Al final, esas características se concatenan con los otros 35 canales de contexto y pasan por un bloque convolucional y una convolución 1×1 que produce el logit z_i de cada celda. El modelo tiene 1 281 745 parámetros; en adelante, E1 designa el punto de control de esta red usado en el artículo y en el prototipo. A diferencia de [7], que detecta un cambio ya ocurrido, aquí la red pronostica el cambio del año siguiente.

III-C. Formulación y función de pérdida

Todas las pérdidas se calculan solo sobre las celdas de la máscara M. Sea $\hat{p}_i = \sigma(z_i)$ la probabilidad predicha para la celda i. U-Net, Siamese U-Net, TransUNet++ y Swin UNETR se entrenan de forma multitarea: además del mapa por celda, una cabeza auxiliar sobre el cuello de botella clasifica el parche (deforestación si al menos 5 % de sus celdas válidas pierde bosque). La pérdida combina la entropía cruzada binaria enmascarada y la pérdida Dice por celda con la entropía cruzada por parche:

$$\mathcal{L}_{\mathrm{BCE}} = \frac{\sum_i M_i\big[-Y_i \log \hat{p}_i - (1-Y_i)\log(1-\hat{p}_i)\big]}{\sum_i M_i}, \qquad (4)$$

$$\mathcal{L}_{\mathrm{Dice}} = 1 - \frac{2\sum_i M_i \hat{p}_i Y_i + 1}{\sum_i M_i \hat{p}_i + \sum_i M_i Y_i + 1}, \qquad (5)$$

$$\mathcal{L} = \mathcal{L}_{\mathrm{CE}}^{\mathrm{parche}} + \lambda\big(\mathcal{L}_{\mathrm{BCE}} + \mathcal{L}_{\mathrm{Dice}}\big), \qquad \lambda = 1, \qquad (6)$$

donde $\mathcal{L}_{\mathrm{CE}}^{\mathrm{parche}}$ es la entropía cruzada con pesos inversos a la frecuencia de cada clase y suavizado de etiquetas de 0.1. El término Dice compensa el desbalance de celdas, porque la pérdida ocupa una fracción pequeña de cada parche; en TransUNet++, el término de segmentación se promedia sobre las cuatro cabezas de la supervisión profunda. ResNet50, como clasificador, usa solo la entropía cruzada por parche, y la Siamese Forest U-Net, solo la salida por celda, sin cabeza por parche. El cuaderno de entrenamiento de E1 no forma parte de los archivos publicados; el paquete de inferencia confirma su arquitectura, sus pesos y su evaluación en validación, pero no documenta la función de pérdida ni el optimizador.

III-D. Entrenamiento y métricas

U-Net, Siamese U-Net, TransUNet++ y Swin UNETR comparten la misma plantilla de entrenamiento: AdamW (tasa de aprendizaje de 10^{-3}, y de 5×10^{-4} en Swin UNETR, más estable para un Transformer entrenado desde cero; decaimiento de pesos de 10^{-4}), una época de calentamiento lineal seguida de decaimiento coseno, lotes de 32, hasta 10 épocas con parada temprana (paciencia 5), precisión mixta y recorte del gradiente a norma 1; la semilla es 42. En la práctica, la U-Net se detuvo por parada temprana en la época 8 (mejor época: 3), mientras que la Siamese U-Net, TransUNet++ y Swin UNETR completaron las 10 épocas, con mejor época 7, 7 y 10, respectivamente; Swin UNETR seguía mejorando al final, por lo que podría beneficiarse de un entrenamiento más largo. Para elegir la época se usa una validación interna: el 15 % de entrenamiento, agrupado en bloques espaciales de 256 celdas para que un parche y su copia aumentada no queden en lados distintos. Esta validación interna es distinta de la validación temporal; por ejemplo, en Swin UNETR el F1-macro por parche fue 0.859 en la interna (934 parches) y 0.863 en la temporal (1 402 parches). Como aumento adicional se aplican volteos y rotaciones de $90°$ a la entrada y a las máscaras. La Siamese Forest U-Net (16 canales en el primer nivel) se entrenó en un cuaderno aparte: se conservó el punto de control de la época 4, el de mayor F1 en validación, y el umbral de 0.65 también se eligió en validación. Las variantes posteriores, ajustadas con Optuna, no se usan en este artículo. Se reportan la precisión, el *recall*, el F1 y el IoU de la clase pérdida, calculados sobre todas las celdas de la máscara de cada conjunto, sin submuestrear. Seguimos así a Engelmann y Toetzke [9], que mostraron que evaluar con un conjunto de prueba balanceado, como en [8], sobreestima el desempeño: el mismo modelo pasó de un F1 de 0.725 con prueba balanceada a 0.197 con la proporción real. El umbral de decisión se elige en validación y se aplica sin cambios en prueba.

IV. Resultados

Se reportan los modelos con resultados disponibles. U-Net, Siamese U-Net (concatenación), TransUNet++ y Swin UNETR se entrenaron con la misma plantilla de código, la misma validación interna y el umbral por celda de 0.5. En los cuatro, la configuración por defecto excluyó los seis canales de historia de pérdida, por lo que usaron 31 de los 37 canales. La Siamese Forest U-Net usa los 37 canales y un umbral de 0.65 elegido en validación. E1 se evaluó solo en validación (el equipo reservó la prueba), por lo que no se afirma que supere a los demás modelos en prueba. De ResNet50 se dispone de ejemplos de validación, que se analizan en la Sección IV-C.

IV-A. Comparación con la línea base

La Tabla IV resume las métricas por celda en prueba (2024–2025) y la Tabla V, en validación (2022–2023), siempre sobre todas las celdas con bosque.

Entre los cuatro modelos con 31 canales, Swin UNETR obtiene el mayor F1 por celda en prueba (0.237), seguido de TransUNet++ (0.224), la Siamese U-Net (0.217) y la U-Net (0.207), y también la mayor precisión media (AP de 0.178), con menos parámetros que la U-Net. En la clasificación por parche, que es otra tarea, Swin UNETR obtiene en prueba un F1-macro de 0.825 y un AUC-ROC de 0.946 (Tabla VI). Su ventaja sobre la U-Net (0.03 de F1) es modesta, pero se repite en validación y en prueba. Las diferencias entre los otros tres, de 0.017 como máximo, son del mismo orden que la variación entre semillas (desviación estándar de 0.01 a 0.02 en el IoU por celda), por lo que no permiten ordenarlos. Los cuatro modelos pierden entre 0.015 y 0.030 de F1 al pasar de validación a prueba. La Siamese Forest U-Net, que sí usa la historia de pérdida, alcanza en validación un F1 de 0.362 y un IoU de 0.221, casi 0.10 puntos de F1 más que el mejor modelo de 31 canales. Este resultado es prometedor, pero no es una comparación concluyente: E1 usa información adicional, su umbral se eligió en ese mismo conjunto y no tiene resultado de prueba. La Fig. 2 muestra esta brecha, y la Fig. 3 compara sus predicciones con la pérdida real en dos parches de validación: la red marca los focos correctos, pero con manchas más extensas que la pérdida observada, lo que explica su *recall* alto y su precisión baja.

Tabla IV
Métricas por celda en prueba (2024–2025), umbral 0.5, 31 canales

Modelo	Prec.	Recall	F1	IoU	AP	Parám.
U-Net (línea base)	0.194	0.222	0.207	0.116	0.167	7.77 M
Siamese U-Net (conc.)	0.198	0.241	0.217	0.122	0.175	9.08 M
TransUNet++	0.192	0.268	0.224	0.126	0.171	12.61 M
Swin UNETR	**0.209**	**0.274**	**0.237**	**0.134**	**0.178**	6.32 M

Tabla V
Métricas por celda en validación (2022–2023)

Modelo	Canales	Umbral	Prec.	Recall	F1	IoU
U-Net	31	0.50	0.232	0.229	0.230	0.130
Siamese U-Net (conc.)	31	0.50	0.235	0.219	0.227	0.128
TransUNet++	31	0.50	0.232	0.248	0.239	0.136
Swin UNETR	31	0.50	0.249	0.287	0.267	0.154
Siamese Forest U-Net	37	0.50	0.226	0.698	0.341	0.206
Siamese Forest U-Net	37	0.65	0.278	0.522	**0.362**	**0.221**

Clasificación por parche y líneas base clásicas. La Tabla VI compara la tarea más sencilla: decidir si un parche tendrá deforestación (al menos 5 % de sus celdas). En validación, el bosque aleatorio sobre estadísticos por canal logra el mayor F1-macro (0.870), por encima de TransUNet++ y Swin UNETR (0.863), la Siamese U-Net (0.856) y la U-Net (0.821). A nivel de parche, una línea base clásica es suficiente; el aporte de las redes profundas está en el mapa por celda, que el bosque aleatorio no produce.

IV-B. Estudio de ablación

La Tabla VII resume las ablaciones más informativas, cada una entrenada con 3 semillas durante 5 épocas y evaluada en validación con el IoU por celda. Como su mejor época cayó entre la 2 y la 5, varias variantes seguían mejorando al

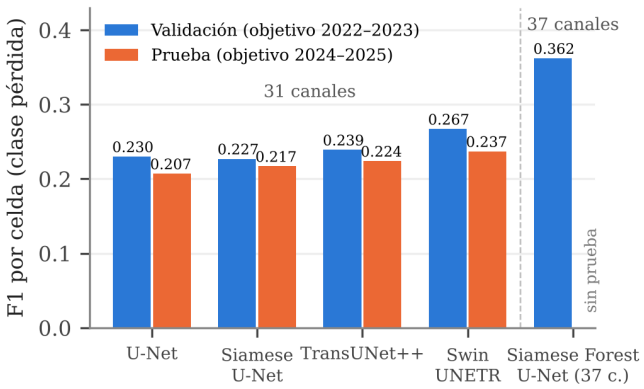


Figura 2. F1 por celda de la clase pérdida. Los cuatro modelos de 31 canales quedan a menos de 0.04 entre sí; la Siamese Forest U-Net, con la historia de pérdida (37 canales), supera ese nivel en validación. Solo se evaluó en validación.

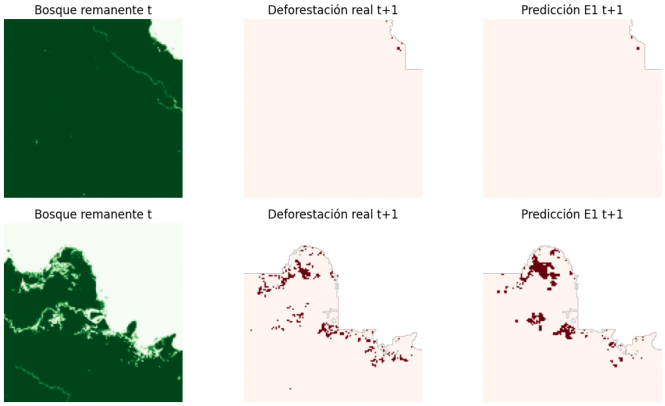


Figura 3. Siamese Forest U-Net en dos parches de validación. Izquierda: bosque remanente en t; centro: pérdida real en $t+1$; derecha: predicción con umbral 0.65. Las zonas en blanco quedan fuera de la máscara de bosque.

terminar: estos valores sirven para comparar variantes entre sí, no como resultado final de cada modelo. La Fig. 4 presenta los mismos valores de forma gráfica.

Tres resultados son claros. Primero, el término Dice es indispensable: con solo entropía cruzada, la U-Net predice siempre "sin pérdida" y el IoU cae a cero, efecto del fuerte desbalance de clases. Segundo, las conexiones de salto son el componente arquitectónico que más importa: sin ellas, el IoU de la U-Net baja de 0.141 a 0.080. Tercero, los componentes más complejos no aportan: quitar el Transformer de TransUNet++ deja el IoU prácticamente igual (0.134 frente a 0.136) con 3.4 M parámetros menos, y la Siamese U-Net no supera a una U-Net de una sola rama (0.138 frente a 0.141). En la red siamesa, la fusión por concatenación supera a la diferencia (0.138 frente a 0.112). En Swin UNETR, quitar las ventanas desplazadas no cambia el IoU (0.153), reducir el ancho a la mitad apenas lo baja (0.146 con 1.60 M parámetros) y sustituirlo por SegFormer lo empeora y lo vuelve más variable entre semillas (0.107 ± 0.020), probablemente porque SegFormer predice a 1/4 de la resolución y pierde los bordes

Tabla VI
CLASIFICACIÓN POR PARCHE (F1-MACRO Y AUC-ROC)

Modelo	Validación F1	Validación AUC	Prueba F1	Prueba AUC
Bosque aleatorio	**0.870**	**0.966**	–	–
Regresión logística	0.846	0.959	–	–
U-Net	0.821	0.949	0.812	0.939
Siamese U-Net (conc.)	0.856	0.964	0.824	**0.949**
TransUNet++	0.863	0.964	0.809	0.943
Swin UNETR	0.863	**0.966**	**0.825**	0.946

Las líneas base clásicas solo se evaluaron en validación.

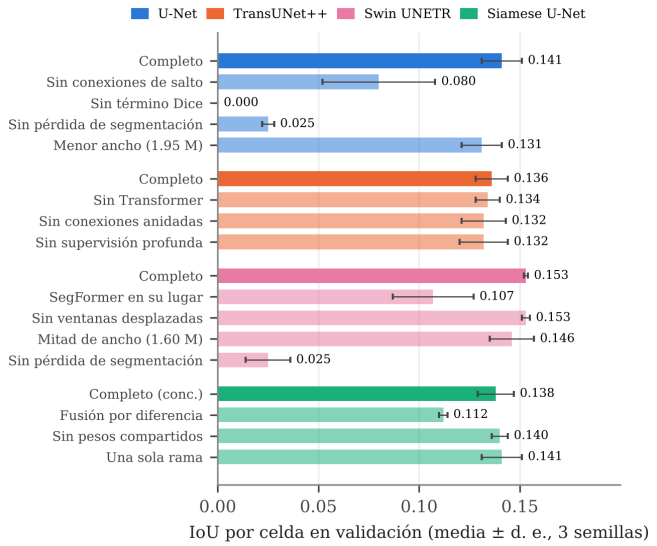


Figura 4. Ablaciones de U-Net, TransUNet++, Swin UNETR y Siamese U-Net (IoU por celda en validación, media ± desviación estándar de 3 semillas). Las barras oscuras son el modelo completo.

finos de la pérdida. Swin UNETR muestra además la menor desviación del IoU entre semillas (0.001), aunque con solo tres semillas y cinco épocas. Estas ablaciones no aíslan el efecto de los seis canales de historia de pérdida: atribuirles la mejora de E1 requiere entrenar la misma red con y sin ellos, lo que queda como trabajo futuro.

IV-C. Interpretabilidad y análisis de errores

Se aplicó Grad-CAM sobre el cuello de botella de cada red para su salida por parche, y se evaluó con dos pruebas (Tabla VIII). En la prueba de *borrado* se ocultan progresivamente las zonas de mayor activación y se mide la caída de la confianza; un área bajo esa curva *menor* que al borrar al azar indica que el mapa señala zonas que el modelo realmente usa. En la prueba de *localización* se cuenta en qué fracción de los parches con deforestación el máximo del mapa cae dentro de la pérdida real (2.6 % al azar). En los cuatro modelos, el área de borrado con Grad-CAM es menor que al azar, con el mayor margen en Swin UNETR (0.519 frente a 0.662), pero la prueba usa solo 64 parches y la dispersión entre ellos es alta (desviación de 0.13 a 0.18), por lo que las diferencias entre modelos son orientativas y no demuestran que la explicación

Tabla VII
ABLACIONES: IOU POR CELDA EN VALIDACIÓN (MEDIA ± D. E., 3 SEMILLAS)

Modelo	Variante	IoU
U-Net	Completo	0.141 ± 0.010
	Sin conexiones de salto	0.080 ± 0.028
	Sin término Dice (solo BCE)	0.000 ± 0.000
	Sin pérdida de segmentación	0.025 ± 0.003
	Menor ancho (1.95 M parám.)	0.131 ± 0.010
TransUNet++	Completo	0.136 ± 0.008
	Sin Transformer (UNet++)	0.134 ± 0.006
	Sin conexiones anidadas	0.132 ± 0.011
	Sin supervisión profunda	0.132 ± 0.012
Swin UNETR	Completo	0.153 ± 0.001
	SegFormer en su lugar	0.107 ± 0.020
	Sin ventanas desplazadas	0.153 ± 0.002
	Mitad de ancho (1.60 M parám.)	0.146 ± 0.011
	Sin pérdida de segmentación	0.025 ± 0.011
Siamese U-Net	Completo (concatenación)	0.138 ± 0.009
	Fusión por diferencia	0.112 ± 0.002
	Sin pesos compartidos	0.140 ± 0.004
	Una sola rama (U-Net)	0.141 ± 0.010

Tabla VIII
INTERPRETABILIDAD Y CALIBRACIÓN (VALIDACIÓN)

Modelo	Borrado (AUC) G-CAM	Azar	Máximo en pérdida G-CAM	Mapa	ECE
U-Net	0.560	0.602	4.5 %	14.0 %	0.061
Siamese U-Net	0.596	0.615	7.0 %	25.0 %	0.039
TransUNet++	0.600	0.645	4.0 %	24.0 %	0.034
Swin UNETR	**0.519**	0.662	6.0 %	22.5 %	0.037

200 parches con deforestación; azar: 2.6 %. Borrado: 64 parches.

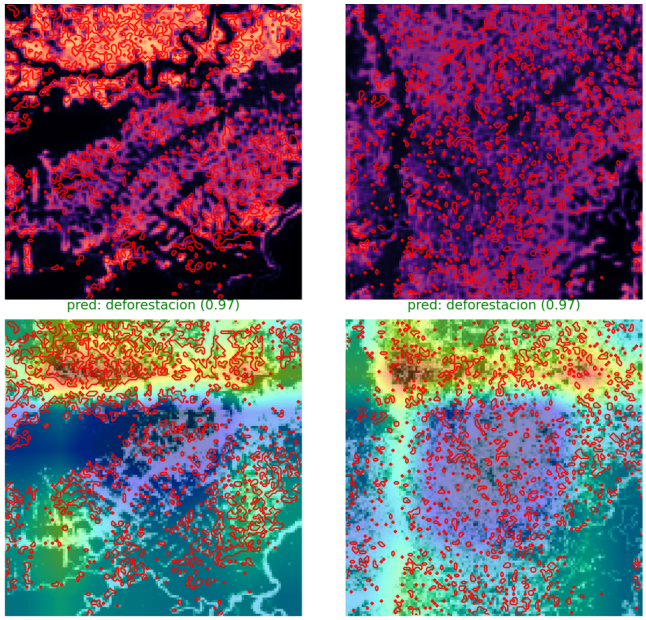


Figura 5. TransUNet++ en dos parches de validación con deforestación, clasificados correctamente con confianza de 0.97. Arriba: mapa de segmentación; abajo: Grad-CAM. Los contornos rojos marcan la pérdida real en $t + 1$. El mapa de segmentación sigue la pérdida, mientras que Grad-CAM se concentra en una franja que solo coincide en parte con ella.

Tabla IX
COSTO COMPUTACIONAL (GPU TESLA T4)

Modelo	Principal (h)	Total (h)	Inferencia
U-Net	0.10	1.53	3.1 ms
Siamese U-Net (conc.)	0.13	1.51	5.4 ms
TransUNet++	0.26	2.99	8.6 ms
Swin UNETR	0.15	1.71	19.0 ms
Total		7.74	

Inferencia: un parche de 128 × 128. Energía: 0.21 kWh (TransUNet++), 0.12 kWh (Swin UNETR).

sea plenamente fiable. Además, Grad-CAM localiza mal la pérdida (4 a 7 %); el mapa de segmentación, en cambio, la localiza de 5 a 10 veces mejor que el azar (14 a 25 %). Para explicar *dónde* se predice la pérdida, el mapa por celda es más útil que Grad-CAM. Las probabilidades por parche están razonablemente calibradas (error de calibración esperado de 0.034 a 0.061). La Fig. 5 ilustra la diferencia entre ambos mapas en TransUNet++. Variantes de Grad-CAM diseñadas para segmentación, como Spectral-Grad-CAM, que cuantifica el aporte de cada banda de entrada [24], permitirían medir el aporte de cada uno de los canales.

En los ejemplos de validación de ResNet50 con mayor confianza, las zonas de mayor activación de Grad-CAM coinciden con áreas de pérdida real densa, y no con el bosque continuo; los parches mal clasificados tienen una confianza menor (de 0.70 a 0.85) que los aciertos (más de 0.90). Los mapas por celda siguen los frentes de deforestación existentes y las riberas. Fuera de la máscara de bosque, donde no se calcula la pérdida, la red puede dar probabilidades altas que no tienen significado. En la clasificación por parche de TransUNet++, los errores se concentran cerca del umbral que define la clase: la tasa de error es casi nula en parches con menos de 0.5 % de pérdida, pero llega a 43 % en los que tienen entre 3 y 5 %. Además, los parches mal clasificados tienen menos celdas válidas (mediana de 86 % frente a 98 % en los aciertos), es decir, suelen estar en bordes del área de estudio o con poco bosque.

IV-D. Costo computacional

Los modelos se entrenaron en Kaggle con una GPU NVIDIA Tesla T4 (15.6 GB), 4 núcleos de CPU y 33.7 GB de RAM, con PyTorch 2.11. La Tabla IX detalla el tiempo de cómputo, que incluye el modelo principal, las líneas base y las ablaciones; el total (7.74 h) corresponde solo a esos cuatro modelos: incluye sus líneas base y ablaciones, entre ellas las de SegFormer, que forman parte del cuaderno de Swin UNETR, pero no incluye E1 ni ResNet50, cuyos tiempos no se registraron, ni la preparación de datos. La preparación de datos (rasterización de 7.57 M polígonos y cálculo de las capas de 10 años) requiere unos 15 GB de RAM, y el conjunto exportado ocupa 16.9 GB.

Tabla X
EVALUACIÓN DE LOS CUADERNOS FRENTE A LOS REQUISITOS DEL PROBLEMA

Criterio	**U-Net**	**Siam.**	**TU++**	**Swin**	**SFU**	**RF**
Predicción por celda $t+1$	Sí	Sí	Sí	Sí	Sí	No
Usa los 37 canales	No	No	No	No	Sí	No
F1 celda (val)	0.230	0.227	0.239	0.267	**0.362**	–
Mejora sobre U-Net $>$ semillas	–	No	No	Leve	N/C	–
Ablación / interpret.	Sí	Sí	Sí	Sí	Parc.	–
Parámetros (M)	7.77	9.08	12.61	6.32	**1.28**	–
Evaluado en prueba	Sí	Sí	Sí	Sí	No	No

Siam.: Siamese U-Net (conc.); TU++: TransUNet++; Swin: Swin UNETR; SFU: Siamese Forest U-Net (E1); RF: bosque aleatorio; N/C: no comparable (otra entrada, sin prueba).

V. DISCUSIÓN

La entrada parece importar más que la arquitectura. Con los mismos 31 canales, cuatro arquitecturas de complejidad muy distinta (de 6.3 a 12.6 M parámetros) quedan a menos de 0.04 de F1 entre sí en prueba: agregar un Transformer a la U-Net (TransUNet++) o una rama siamesa no la mejora, y el mejor de los cuatro, Swin UNETR, la supera en 0.03. En cambio, E1, que incorpora la historia de pérdida, mejora en casi 0.10 el F1 en validación respecto a Swin UNETR. Esa diferencia no puede atribuirse solo a la información de entrada: E1 tiene otra arquitectura, su umbral se ajustó en validación y no se ha evaluado en prueba. La hipótesis es, sin embargo, coherente con Engelmann y Toetzke [9], cuyo análisis de importancia de variables encontró que la distancia a la deforestación previa es por mucho la variable más informativa, con ForestCast [4], donde el historial de pérdida por sí solo bastó para obtener buenos resultados, y con el avance de la deforestación como frente desde bordes y vías [3]. Confirmarla requiere evaluar E1 en prueba y reentrenar los demás modelos con los 37 canales.

¿Qué modelo aplica mejor al problema? La Tabla X resume la evidencia disponible de cada cuaderno frente a los criterios que exige el problema. No es un *ranking*: los modelos difieren en canales de entrada y en si tienen evaluación en prueba. Los criterios son predecir por celda el año $t+1$ dentro de la máscara de bosque, usar los 37 canales sin excluir la historia de pérdida, superar a la U-Net por más que la variación entre semillas y cubrir ablación, interpretabilidad y costo.

La Siamese Forest U-Net es la arquitectura que proponemos, porque es la que mejor se ajusta al problema: integra los dos estados del bosque y la historia de pérdida, que es la señal más informativa del frente de deforestación [4], [9], en una red compacta de 1.28 M parámetros, de 5 a 10 veces menos que las demás. Su F1 de 0.362 y su IoU de 0.221 son los mejores valores por celda del equipo, pero son resultados preliminares de validación: no es válido afirmar todavía que supera a Swin UNETR en prueba. Entre los modelos con evaluación en prueba, Swin UNETR es el mejor: tiene el mayor F1, IoU y AP por celda en validación y en prueba, la menor desviación del IoU entre las tres semillas de las ablaciones (0.001, frente a 0.008–0.010 de los demás) y menos parámetros que la U-Net, aunque su latencia es mayor (19.0 ms por parche). TransUNet++ no supera a la U-Net por más que la variación entre semillas. Para clasificar parches, un bosque aleatorio es competitivo, pero no produce mapas por celda. En síntesis, E1 es el modelo propuesto, con la reserva indicada; Swin UNETR, el mejor modelo validado en prueba; y la U-Net, la línea base.

Comparación con trabajos previos. Los F1 por celda en prueba (0.207 a 0.237) y el 0.362 de la red siamesa en validación son del mismo orden que el 0.263 por píxel de Engelmann y Toetzke [9], el trabajo con un protocolo de evaluación más parecido al nuestro, aunque nuestras celdas de 278 m son más gruesas que sus píxeles de 30 m. Los valores de Ball *et al.* [8] no son comparables, porque se midieron sobre un conjunto de prueba balanceado. A nivel de parche, donde la tarea es más fácil, todos los modelos superan un F1-macro de 0.80, igual que en [9], donde el F1 subió de 0.263 a 0.608 al agregar en celdas de 1.5 km.

Limitaciones de los datos. (i) *Información del futuro en algunas fuentes*: OpenStreetMap es una foto de 2026 y la red del MTC es de 2018, así que, para años anteriores, incluyen vías que todavía no existían; como las vías están entre los factores más fuertes de la deforestación [3], esta información puede inflar los resultados; no se hizo una ablación sin estas fuentes que mida cuánto. No es una fuga entre parches de entrenamiento y prueba, pero impide usar el modelo tal cual como pronóstico en tiempo real. La climatología de lluvia se calcula con 2015–2025, que incluye los años de validación y prueba. (ii) *Resolución y objetivo*: una celda de 278 m cuenta como positiva aunque solo pierda un píxel de 30 m, por lo que el modelo predice dónde habrá alguna pérdida, no cuánta. (iii) *Rasterización*: en un recuadro de prueba de $\approx$11 km, el método en dos pasos subestimó el área perdida en 16.6 % frente a la suma de los polígonos, lo que importa si se quieren estimar hectáreas. (iv) *Consistencia del objetivo*: en 2025 se excluye la pérdida natural, pero en los años anteriores Geobosques no la separa. (v) *Validación espacial*: las tres particiones cubren la misma región en años distintos, por lo que no se evaluó la generalización a regiones no vistas; una validación por bloques espaciales, cuyo tamaño y forma influyen en la estimación del error [25], queda pendiente. (vi) No se incluyeron propiedades físicas del suelo; MapBiomas describe su cobertura y uso. En ForestCast [4], las capas auxiliares derivadas del terreno aportaron poco a los mejores modelos, lo que sugiere que esta omisión tiene un impacto limitado. (vii) *Degradación*: el objetivo solo registra la pérdida total del bosque; la tala selectiva de baja intensidad, que en la Amazonía peruana las herramientas de monitoreo habituales detectan muy por debajo de su extensión real [26], no se predice.

Sesgos y riesgos de uso. Los errores de Geobosques y de las demás fuentes se trasladan al modelo, y OpenStreetMap está más completo cerca de las ciudades que en la selva remota. Un mapa de riesgo usado sin contexto podría estigmatizar a comunidades indígenas o a pequeños agricultores, o llevar a desatender zonas de bajo riesgo predicho donde aparecen nuevos frentes. Recomendamos usarlo como apoyo para priorizar

la vigilancia, el uso que Elezi y Garza [10] formalizan como un problema de *ranking* espacial, junto con la verificación de campo y las alertas de GEOBOSQUES [2], y no como prueba de una infracción.

Impacto. Las zonas de amortiguamiento presentan la misma tasa de pérdida que las áreas sin protección (3.63 % en 2022), un patrón también observado por Rojas *et al.* [3]. Un mapa de riesgo anual podría ayudar al SERNANP y a los gobiernos regionales a priorizar la vigilancia en esas zonas. Con ese fin, el equipo construyó el prototipo *Observatorio Forestal IA*: una aplicación web con una API REST (FastAPI) que sirve las predicciones de la Siamese Forest U-Net con el umbral de 0.65, registra cada inferencia en MLflow y verifica los pesos del modelo con su huella SHA-256, y una interfaz que muestra en un mapa interactivo la pérdida real y la predicha de cada parche y su mapa Grad-CAM; por ahora funciona solo sobre el conjunto de validación y no es todavía una herramienta de vigilancia operativa.

VI. Conclusiones

Los modelos desarrollados permiten priorizar la vigilancia forestal con una eficacia muy superior al azar. Nuestro modelo propuesto, la Siamese Forest U-Net, es el único que incorpora la historia de pérdida: de cada 100 celdas que señala como de riesgo, 28 registran pérdida (unas 10 veces más que al azar) y detecta el 52 % de la pérdida, con un F1 de 0.362 en validación. Como aún no se ha evaluado en prueba, su ventaja debe confirmarse; el resultado respalda la hipótesis de que la historia de pérdida pesa más que la complejidad de la arquitectura. Entre los modelos evaluados en prueba, todos de 31 canales, Swin UNETR es el mejor (F1 de 0.237, frente a 0.207 de la U-Net): unas 20 de cada 100 celdas señaladas pierden bosque, 8 veces más que al azar. Una U-Net con conexiones de salto y pérdida Dice rinde casi igual que las variantes con Transformer o ramas siamesas. A nivel de parche, un bosque aleatorio es competitivo; el valor de las redes profundas está en producir mapas de riesgo por celda que indican dónde concentrar los patrullajes.

Como trabajo inmediato proponemos evaluar E1 en prueba con el umbral fijado en validación, entrenarla con y sin los canales de historia de pérdida, documentar su entrenamiento, reentrenar los demás modelos con los 37 canales, entrenar Swin UNETR durante más épocas, probar codificadores pre-entrenados o reemplazar parte de los canales por representaciones de modelos fundacionales de observación terrestre, como AlphaEarth Foundations [27] o TESSERA [28], usar fuentes de vías y clima con fecha compatible con cada año objetivo, predecir la fracción perdida en lugar de un valor binario para estimar hectáreas, extender el horizonte a 2 y 5 años, y evaluar en regiones no vistas.

Disponibilidad de código

El código y las configuraciones están en:
https://github.com/CodeandoDevTiktok/MIA_Deep_Learning_ExamenFinal

Datos y pesos: https://www.kaggle.com/datasets/gerardobarzola/dataset-deforestacion.

Todos los resultados proceden del equipo.

CONTRIBUCIONES

Integrante	Responsabilidades
Gerardo Manuel Barzola Salvador	Curación y preparación del dataset; U-Net con backbone (ResNet/EfficientNet) y ResNet50.
Rocío Ivett Castromonte Quiroz	Siamese U-Net y redes de detección de cambios; prototipo y demo del Observatorio Forestal IA.
José Luis Núñez Veintimilla	Revisión metodológica, experimentos, análisis de resultados y artículo.
Ubil Rodríguez Arrascue	Implementación y evaluación de TransUNet++ y U-Net.
Miguel Ángel Salinas Marcos	Implementación y evaluación de Swin UNETR y SegFormer.

Trabajo conjunto: diseño experimental, entrenamiento, líneas base, ablaciones, interpretabilidad, documentación, artículo y presentación.

EVIDENCIAS GRÁFICAS COMPLEMENTARIAS

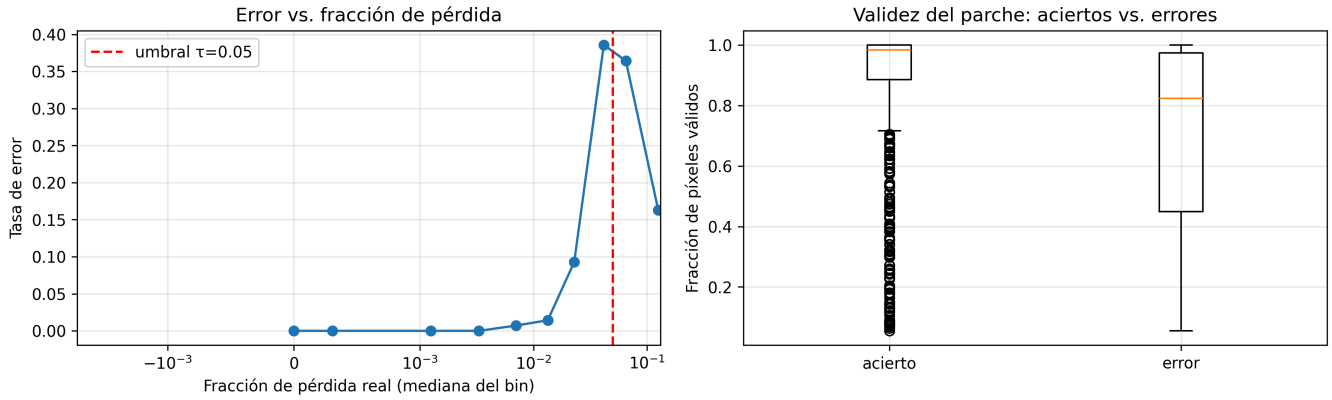


Figura adicional A. Errores frente a fracción de pérdida y validez del parche.

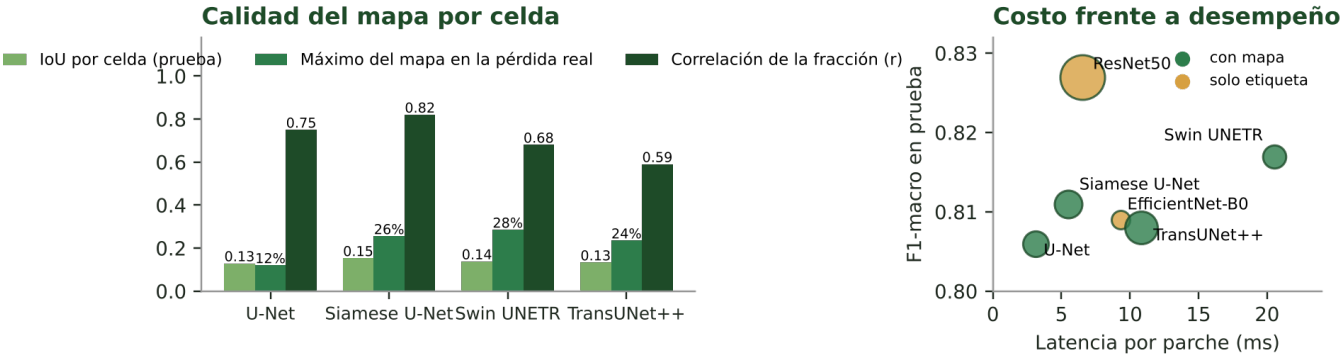


Figura adicional B. Calidad de mapas por celda de los cuatro modelos.

REFERENCIAS

[1] N. García Soto and M. Koelle, "Deforestation in Peru: Key facts and main drivers," OECD Economics Department Working Papers, no. 1846, OECD Publishing, Tech. Rep., 2025.

[2] Ministerio del Ambiente del Perú, "GEOBOSQUES: Plataforma de monitoreo de cambios sobre la cobertura de los bosques," https://geobosques.minam.gob.pe, consultado: nov. 2026.

[3] E. Rojas, B. R. Zutta, Y. K. Velazco, J. G. Montoya-Zumaeta, and M. Salvà-Catarineu, "Deforestation risk in the Peruvian Amazon basin," *Environmental Conservation*, vol. 48, no. 4, pp. 310–319, 2021.

[4] M. Overlan *et al.*, "ForestCast: Forecasting deforestation risk at scale with deep learning," 2025, earthArXiv preprint, 2025.

[5] O. Ronneberger, P. Fischer, and T. Brox, "U-Net: Convolutional networks for biomedical image segmentation," in *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, ser. LNCS, vol. 9351, 2015, pp. 234–241.

[6] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin, "Attention is all you need," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017.

[7] R. C. Daudt, B. L. Saux, and A. Boulch, "Fully convolutional Siamese networks for change detection," in *Proc. IEEE Int. Conf. Image Processing (ICIP)*, 2018, pp. 4063–4067.

[8] J. G. C. Ball, K. Petrova, D. A. Coomes, and S. Flaxman, "Using deep convolutional neural networks to forecast spatial patterns of Amazonian deforestation," *Methods in Ecology and Evolution*, vol. 13, no. 11, 2022.

[9] T. Engelmann and M. Toetzke, "Can deep learning help to forecast deforestation in the Amazonian rainforest?" in *NeurIPS 2023 Workshop on Tackling Climate Change with Machine Learning*, 2023.

[10] K. Elezi and P. Garza, "Learning to rank in 2D: Differentiable spatial prioritization for deforestation forecast," *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, vol. 19, pp. 29 995–30 014, 2026.

[11] U. S. Guimarães, T. B. Rodrigues, A. C. Vieira, E. M. Hung *et al.*, "Deep learning models to map deforestation based on Sentinel 1 coherent features in the southern border of Amazon," *Science of Remote Sensing*, vol. 12, p. 100279, 2025.

[12] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 770–778.

[13] J. Chen, Y. Lu, Q. Yu, X. Luo, E. Adeli, Y. Wang, L. Lu, A. L. Yuille, and Y. Zhou, "TransUNet: Transformers make strong encoders for medical image segmentation," *arXiv preprint arXiv:2102.04306*, 2021.

[14] A. Hatamizadeh, V. Nath, Y. Tang, D. Yang, H. R. Roth, and D. Xu, "Swin UNETR: Swin transformers for semantic segmentation of brain tumors in MRI images," in *Brainlesion: Glioma, Multiple Sclerosis, Stroke and Traumatic Brain Injuries (BrainLes 2021)*, ser. LNCS, vol. 12962, 2022, pp. 272–284.

[15] S. Chen, X. Wang, M. Shi, G. Tao, S. Qiao, and Z. Chen, "Developing interpretable deep learning model for subtropical forest type classification using Beijing-2, Sentinel-1, and time-series NDVI data of Sentinel-2," *Forests*, vol. 16, no. 11, p. 1709, 2025.

[16] Z. Zhou, M. M. R. Siddiquee, N. Tajbakhsh, and J. Liang, "UNet++: A nested U-Net architecture for medical image segmentation," in *Deep Learning in Medical Image Analysis and Multimodal Learning for Clinical Decision Support (DLMIA)*, ser. LNCS, vol. 11045, 2018, pp. 3–11.

[17] E. Xie, W. Wang, Z. Yu, A. Anandkumar, J. M. Alvarez, and P. Luo, "SegFormer: Simple and efficient design for semantic segmentation with transformers," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 34, 2021.

[18] T. G. Farr, P. A. Rosen, E. Caro, R. Crippen, R. Duren, S. Hensley, M. Kobrick, M. Paller, E. Rodriguez, L. Roth, D. Seal, S. Shaffer, J. Shimada, J. Umland, M. Werner, M. Oskin, D. Burbank, and D. Alsdorf, "The Shuttle Radar Topography Mission," *Reviews of Geophysics*, vol. 45, no. 2, 2007.

[19] C. Funk, P. Peterson, M. Landsfeld, D. Pedreros, J. Verdin, S. Shukla, G. Husak, J. Rowland, L. Harrison, A. Hoell, and J. Michaelsen, "The climate hazards infrared precipitation with stations—a new environmental record for monitoring extremes," *Scientific Data*, vol. 2, p. 150066, 2015.

[20] Servicio Nacional de Áreas Naturales Protegidas por el Estado (SERNANP), "Límites de áreas naturales protegidas, áreas de conservación regional y privada, zonas reservadas y zonas de amortiguamiento," https://www.gob.pe/sernanp, consultado: nov. 2026.

[21] OpenStreetMap contributors, "OpenStreetMap: extracto de Perú (geofabrik)," https://download.geofabrik.de, licencia ODbL. Consultado: 2026.

[22] Ministerio de Transportes y Comunicaciones del Perú, "Red vial nacional, departamental y vecinal (diciembre de 2018)," capas vectoriales oficiales.

[23] MapBiomas Perú, "Mapas anuales de cobertura y uso del suelo del Perú," https://peru.mapbiomas.org, consultado: nov. 2026.

[24] S. Ebrahimi and S. Kumar, "What helps to detect what? Explainable AI and multisensor fusion for semantic segmentation of simultaneous crop and land cover land use delineation," *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, vol. 18, 2025.

[25] A. Stock, "Choosing blocks for spatial cross-validation: lessons from a marine remote sensing case study," *Frontiers in Remote Sensing*, vol. 6, p. 1531097, 2025.

[26] C. G. Bousfield, D. P. Edwards, M. G. Hethcoat *et al.*, "Mapping low-intensity selective logging across the Peruvian Amazon," *Environmental Research Letters*, vol. 21, no. 3, p. 034013, 2026.

[27] C. F. Brown, M. R. Kazmierski, V. J. Pasquarella *et al.*, "AlphaEarth Foundations: An embedding field model for accurate and efficient global mapping from sparse label data," 2025, arXiv:2507.22291, 2025.

[28] Z. Feng, C. Atzberger, S. Jaffer *et al.*, "TESSERA: Precomputed FAIR global pixel embeddings for Earth representation and analysis," 2025, arXiv:2506.20380, 2025.